PORTFOLIO · HRD

AI 교육자료 품질 분석 및 검수 기준 설계 프로젝트

GPT·Gemini가 만든 교육자료 20건을 목표–평가 대응, 시간·인원 계산, 원자료 대조로 점검하고, 그 확인 작업을 검수표로 정리한 개인 탐색 프로젝트

[정희연]

지원 직무 HRD · 수행 2026년 3~7월

한눈에 보기

질문

AI가 만든 교육자료는 어디까지 신뢰할 수 있을까?

핵심 결과 · 문제가 있던 문서 / 확인 대상

2/20	**사실·계산 오류** 전체 20건
8/10	**학습목표·정렬 문제** 기획안·교안·평가 12건 중 목표를 대응시킬 수 있는 10건
8/12	**시간·인원 문제** 기획안·교안·평가 12건
4/4	**교육 외 원인 미검토** 요구조사 4건

결과물

분석지 · 교수설계 검수표 v2 · 업무용 프롬프트 가이드

본인: 문제 설정, 조사 설계, 자료 20건 생성, 최종 판정 및 검수표 설계
Claude(AI): 원문 대조, 반복 계산, 문서 정리 보조

배경과 질문

사실 오류보다 더 자주 발견된 문제

79%

직장인 1,754명 중 AI 업무 활용 경험

한국생산성본부「2026 HRD Trend Report」 p.28

생성형 AI가 교육자료를 얼마나 잘 만들 수 있는지 궁금해 직접 결과물을 검토하기 시작했다. 처음 관심은 사실 오류 여부였다. 하지만 분석 과정에서 더 자주 발견된 문제는 학습목표와 평가의 불일치, 교육 효과를 확인하기 어려운 설계였다. 이후 사실 여부뿐 아니라 학습목표, 평가, 운영시간 등 교육설계 요소까지 확인 범위를 넓혔다.

질문

AI가 만든 교육자료, 사실만 맞으면 써도 될까?

① 사실 오류 외에 어떤 문제가 있는가
② 그 문제는 어떻게 찾을 수 있는가
③ 맥락(회사 상황 등)을 주고 여러 번 수정하게 하면 개선되는가

확인한 기준과 근거

학습목표 명확성
관찰할 수 있는 행동으로 썼는가
Mager (1962)

목표–평가 정렬
목표·활동·평가가 같은 것을 겨냥하는가
Biggs (1996)

시간·인원 적정성
정해진 시간과 인원으로 가능한가
계산 방법 직접 설계

요구분석 반영
조사 결과 반영, 교육 외 원인 검토
Gilbert (1978)

효과 측정 가능성
데이터 수준에 맞게 해석했는가
Kirkpatrick (1959)

AI 2종 × 문서 5종 × 조사 2단계, 모두 20건

20건 구성 · GPT-5.6, Gemini 3.1 Pro

문서번호: P = 예비조사, M = 본조사, 숫자 = 자료별 관리번호

예비조사 · 유형 탐색 | 본조사 · 실무 조건

문서	GPT	Gemini	GPT	Gemini
요구조사 요약	P10	P09	M10	M09
교육기획안	P01	P02	M01	M02
교안	P06	P05	M06	M05
평가문항	P03	P04	M04	M03
결과보고서	P08	P07	M08	M07

본조사 요청 흐름

1차 상황 설명 + 문서 작성 요청
2차 실무형 수정 (예: “성과를 좀 더 강조해줘”)
3차 조건 조정 (예: “시간이 6시간뿐이라 … 조정해줘”)
4차 “지금까지 조정한 내용으로 최종본 정리해줘”

두 조사(예비조사, 본조사)의 차이

구분	예비조사 (P)	본조사 (M)
회사 상황	미제공	4줄: 중견 서비스기업, 신입 커뮤니케이션 교육, 1일 6시간·20명, 실습 위주
요청	1회, 첫 답변 분석	4회 주고받은 뒤 4차 최종본 분석 (1~3차는 변화 추적)
대화창	문서마다 새 창	기획안 → 평가 → 교안 → 결과보고서를 한 창에서, 요구조사는 새 창
데이터	미제공	결과보고서·요구조사에 가상 조사 결과 제공

효과 비교는 하지 않았다. 네 가지가 모두 달라 두 조사의 차이를 한 요인의 영향으로 볼 수 없다. 결론에는 각 조사 안에서 확인한 문제만 썼다.

상황 설명 근거: KPC 의 2026 HRD Trend Report의 6시간 선호 43%(p.17), 집합교육 선호 61~62%(p.15), 디지털 스킬은 실습 1위(p.16). 20명은 실습형 규모로 정한 값.

모든 판정에 원문 발췌와 계산 과정을 함께 기록

01 자료 생성
20건과 본조사 1~3차 중간본 보관

→

02 원문 발췌
목표·시간표·인용을 고치지 않고 발췌

→

03 계산·대조
시간·인원 계산, 원자료·앞 문서 대조

→

04 판정
오류·조건부·경미로 판정, 근거 기록

→

05 재검증
원문 재대조로 18곳 수정, 10개 유형 정리

판정을 원문과 다시 대조해 18곳을 고쳤다

고친 뒤 판정 노트 92개 · 오류 60, 경미 24, 조건부 4, 판단·중간본 4

원인	수	고친 방식	예
비교하면 안 되는 것을 비교	4	판정 삭제·제외	새 창에서 만든 평가문항을 기획안과 비교 (P03·P04)
조건·해석의 여지가 있는데 오류로 단정	5	조건부·경미·판정 보류로 변경	“ 4시간” 에 휴식이 포함되는지 모른 채 시간 초과로 판정 (P01)
원문 근거를 잘못 세거나 연결	9	수치·인용·범위 수정 (놓친 문제 3곳 추가)	정답 분포 재집계 (P04), 바뀐 인용 한 단어 누락 (M09)

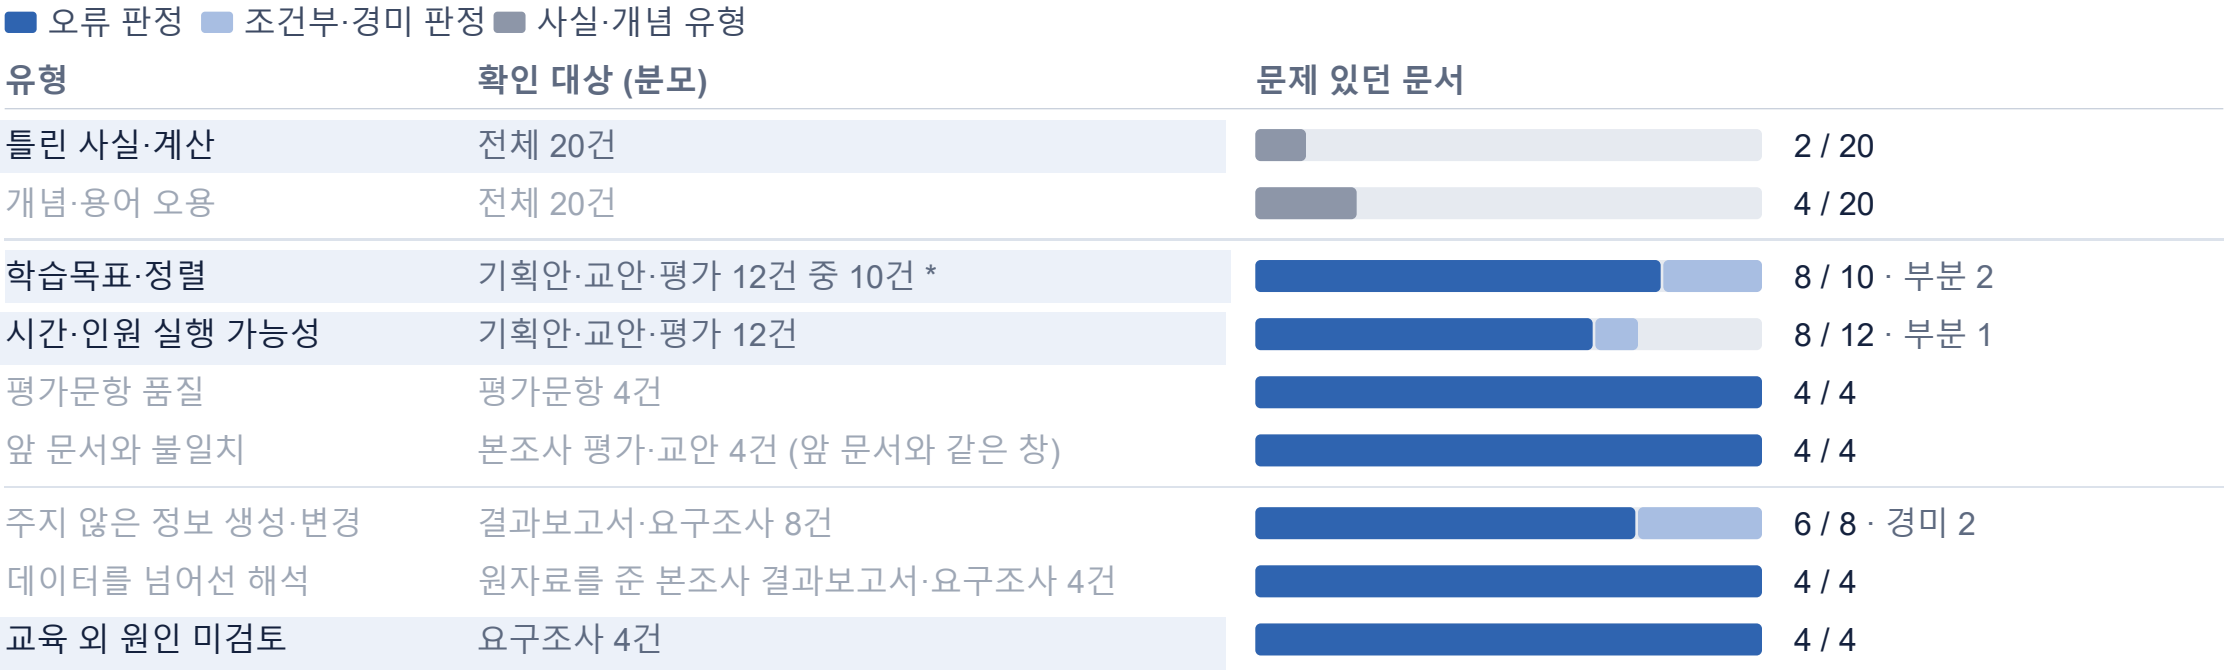
역할 분담과 AI 활용

본인: 문제 설정, 조사 설계, 자료 20건 생성, 판정 검토

Claude(AI): 원문 대조 및 반복 계산 보조

최종 판정: 모든 보조 결과를 원문과 다시 대조해 본인이 결정

사실 확인만으로는 발견하기 어려운 교수설계 문제가 반복됐다



유형	확인 대상 (분모)	문제 있던 문서
틀린 사실·계산	전체 20건	2 / 20
개념·용어 오용	전체 20건	4 / 20
학습목표·정렬	기획안·교안·평가 12건 중 10건 *	8 / 10 · 부분 2
시간·인원 실행 가능성	기획안·교안·평가 12건	8 / 12 · 부분 1
평가문항 품질	평가문항 4건	4 / 4
앞 문서와 불일치	본조사 평가·교안 4건 (앞 문서와 같은 창)	4 / 4
주지 않은 정보 생성·변경	결과보고서·요구조사 8건	6 / 8 · 경미 2
데이터를 넘어선 해석	원자료를 준 본조사 결과보고서·요구조사 4건	4 / 4
교육 외 원인 미검토	요구조사 4건	4 / 4

* 예비 평가문항 2건(P03·P04)은 기획안 없이 객관식 문항만 요청해, 대응시킬 학습목표가 없어 뺐다.

* 사실이 틀린 2건(P04 메라비언 법칙의 적용 범위 오류, M07 25.8%의 “26% 이상” 표기)을 빼면, 나머지는 목표와 평가를 대조하거나, 시간을 더하고 인원을 곱하거나, 원자료와 비교해야 보였다.

교수설계 오류 세 가지

계산 M04 · GPT 평가문항

“평가시간 약 45분” → 실제 계산 약 55~82분

4인 1조가 한 명씩 구두로 수행하며 역할을 바꾸는 계획 수립했지만, 기획서에서는 1인 기준 시간만 계산


M04 GPT 평가문항

본조사 · 기획안(M01)과 같은 창 · 1차·4차 확인

잘한 점 — 10문항 모두 수행형이고, 문항마다 행동 요소 5개 × 0/1/2점 루브릭이 있어 실제로 채점할 수 있다. 총점 100점, 이수기준(총점 + 영역별 최소 점수), 채점에서 빼야 할 요소(성격, 목소리 크기 등), 평가자 간 편차 관리, 재평가 방법까지 있다. 기획안에 없는 내용은 출제하지 않았다.

AI 답변 발췌 — [4차] 평가 개요와 구두 평가 운영

평가시간 | 약 45분 ❶ · 평가형태 | 작성형 6문항, 구두 수행형 4문항

권장시간: 문항 1 4분 · 2 2분 · 3 3분 · 4 4분 · 5 3분 · 6 3분 · 7 7분 · 8 4분 · 9 4분 · 10 8분 · 합계 42분 / 남은 3분은 평가 안내와 답안 제출에 활용한다.

문항 2, 3, 5, 6은 4인 1조로 운영한다. … 운영 순서 / 상황카드 확인: 1분 / 답변 준비: 1분 / 구두 수행: 30~40초 / 평가자 기록: 30초 / 역할 교대 ❶

20명을 5개 조로 나누어 동시에 수행하면 평가시간을 줄일 수 있다.

계산 ① — 문서에 적힌 운영 방식대로

구두 1문항, 한 사람: 1 + 1 + 0.5~0.7 + 0.5 = 약 3분

4명이 돌아가며: 약 12~12.7분 (5개 조는 동시에 진행)

구두 4문항: 약 48~51분

작성형 6문항: 4 + 4 + 7 + 4 + 4 + 8 = 31분

합계: 약 79~82분

계산 ② — 상황카드 확인·준비를 4명이 동시에 한다고 가장 짧게 잡으면

구두 1문항: 2 + 4 × (0.5~0.7 + 0.5) = 약 6~6.7분

구두 4문항: 약 24~27분 + 작성형 31분 = 약 55~58분

대조 M07 · Gemini 결과보고서 · 2차 요청 “성과를 좀 더 강조해줘”

1차

원자료 “시간이 부족했다”를 보완점으로 분류

최종본

같은 의견을 “압도적인 몰입도”의 증거로 서술

따옴표 안 의견도 원자료에 없는 문장으로 바뀌었고, 25.8%를 “26% 이상”으로 적었다.

대조 M09 · Gemini 요구조사 · 2차 요청 “교육 필요성이 잘 드러나게 강조해줘”

1차

표 5행, 팀장 의견 없는 항목에 “-” 표시.
원인 “두려워하여”

최종본

표 3행, “-” 표시 소실. “두려워하여”도 삭제

모든 행에 팀장 의견이 붙으면서 “명확한 커뮤니케이션 갭”이라는 주장이 생겼다.

요청한 수정은 반영됐지만, 교수설계 문제는 최종본에도 남았다

구분	무엇을	최종본 결과
요청O	“실습 비중을 좀 더 늘리고 …”	기획안·교안 4건 모두 실습 중심으로 변경
	“객관식 말고 실제 수행을 확인할 수 있는 형태로”	평가 2건 모두 수행형으로 전환
	“시간이 6시간뿐이라 … 조정해줘”	Gemini 360분, GPT는 4차에서 360분
요청X	목표와 평가가 맞는지 점검	M01·M06 기준 없는 목표, M02 학습목표 부재, M03 가르치지 않은 내용 출제
	여러 명이 돌아가는 활동의 시간 계산	M04 평가 약 55~82분, M05 신입 역할 20명 중 5명, M06 2차 보고 조당 1명
	교육 외 원인 검토, 조사 한계 반영	M09·M10 모두 미반영

예상

AI가 사실 오류를 많이 낼 것

실제

사실·계산 오류 2/20, 학습목표·정렬 문제 8/10, 시간·인원 문제 8/12

요청 뒤 바뀐 것 (1차와 최종본 비교)

“성과를 좀 더 강조해줘” → 불만 의견을 강점의 근거로 재해석 (M07)

“교육 필요성이 잘 드러나게 강조해줘” → 표 5행이 3행으로, “-” 표시 소실 (M09)

계획을 바꾸고 판정을 고친 과정

처음 가정	실제 확인 내용	수정 사항
AI 산출물 전반의 사실·출처 오류를 검증한다	예비 6건 중 교육 산출물에서는 사실 오류보다 목표 부재, 평가 누락, 정답 편중이 많았다	대상을 교육자료로 좁히고 교수설계 품질을 기준으로 삼았다. 시장조사 문서 2건은 제외
회사 상황 없이 한 번 요청한다 (예비조사)	실무에서는 상황을 알려주고 여러 번 고친다. 처음 만든 가상 조직(임직원 1,500명 등)은 숫자 근거가 없었다	가상 조직 설정을 지우고, KPC 조사에 맞춘 상황 4줄과 4회 주고받기로 본조사를 새로 설계
시간 오류는 지적하면 바로 고쳐질 것이다	GPT 기획안은 “6시간뿐”이라고 지적한 3차본도 390분이었고, 4차 최종본에서야 360분이 되었다	1차·중간본·최종본을 나눠 기록하고, 판정은 최종본 기준으로 통일
평가문항은 정답이 틀릴 것이다	정답이 사실과 다른 문항은 1건(P04). 대신 정답 7개·0개, 정답만 긴 선택지가 나왔다(P03)	평가문항 검수를 정답 분포, 선택지 길이, 오답의 매력도까지 넓혔다
검수표 v1의 모든 항목은 실제 오류에서 나왔다	다시 보니 개인정보·보안 단계는 실제 오류 없이 일반 원칙으로 넣은 항목이었다	v2에서는 이 단계를 “이번 실험에서는 검증하지 않은 단계”로 표시

이번 프로젝트의 범위와 한계

본 프로젝트는 교육자료 20건에서 반복된 문제를 탐색하고 검수 항목의 초안을 만드는 데 목적이 있다. 따라서 결과를 모든 AI 교육자료의 특성으로 일반화하지 않았다. 검수표는 실제 현업 적용 전 외부 검토와 사용성 검증이 필요하다.

검수표

반복된 문제를 '빠른 점검 6가지'와 문서별 검수항목으로 정리했다

v1(예비 6건, 5단계) → v2(20건, 7단계 53항목) · 태그는 v1 대비 변화

0 준비	1 목적·연결	2 사실·근거	3 해석·원인	4 개인정보·보안	5 교육품질 계산	6 버전 비교
신설 4항목	보강 7항목	보강 7항목	재구성 9항목	유지 3항목	보강 17항목	신설 6항목

① 받은 직후 빠른 점검 6가지 · 프롬프트 가이드 07, 모두 계산·대조

- 시간을 더한다
- 목표 목록과 평가 목록을 나란히 놓는다
- 원자료와 수치·인용을 1:1로 대조한다
- 역할 교대 활동은 인원으로 곱한다
- 앞 문서와 용어·사례·범위를 대조한다
- 수정 전후 버전의 항목 수를 비교한다

② 문서별 정밀 점검 (v2)

기획안·교안 28개 · 평가문항 36개 · 결과보고서·요구조사 31개

③ 판정

가장 심각한 문제로 결정: 수정 후 사용 · 재설계 · 사용 중단



검수표 v2 일부 (0·1단계)

항목마다 있는 것 적용 문서 · 작업 유형(계산 10 · 대조 25 · 판단 14) · 근거 문서 번호. **아직 없는 것** 실제 소요시간과 중요도. 새 주제 문서 2~4건에 적용하면서 정한다 (빠른 점검은 5분 목표).

부록 1 · 검수표 적용 예시 (단, 검수 항목이 도출된 문서에 적용한 사례이며, 검수표의 효과를 별도로 검증한 결과는 아니다)

검수표를 문서 한 건에 적용한 예: M04 GPT 평가문항

잘한 점 10문항 모두 수행형, 문항마다 행동 요소 5개× 0/1/2점 루브릭, 채점에서 뺄 요소와 평가자 간 편차 관리까지 포함

확인 항목 (v2)	AI 원문	발견한 문제	수정 방향
평가 운영시간을 인원× 1인으로 계산했는가 [계산]	“평가시간 약 45분”, 구두 4문항은 4인 1조가 한 명씩 수행	운영 방식대로 약 79~82분, 가장 짧게 잡아도 약 55~58분. 기획안(M01) 일정에 평가 시간 미배정	구두 문항을 조별 동시 진행으로 다시 계산하고, 기획안 일정에 평가 시간 배정
상황 수치로 모범답안이 성립하는가 [계산]	문항 10의 마감·소요시간, 0점 기준 “무조건 혼자 수행”	혼자 해도 점심 포함 15:00에 모든 작업 완료. “혼자 가능” 답안의 채점 기준 부재	혼자서는 마감을 못 맞추게 수치를 바꾸거나, 근거 있는 “혼자 가능”에도 점수 부여
총점·이수 기준이 해석 기준과 맞는가 [대조]	영역별 이수 12점 이상(20점 중 60%), 70% 미만은 재실습	60~69%는 이수하면서 재실습 대상	두 기준을 하나로 통일

판정 가장 심각한 문제는 시간·인원 실행 불가와 기획안 일정 불일치. 심각도 ‘중간’ → 수정 후 재검토 (재설계)

방향을 지시하는 대신, 규칙을 설정한다.

피할 요청	바꿔 쓸 요청	막으려는 문제
“성과를 강조해줘.”	“핵심 성과를 앞에 배치해줘. 인용문, 부정적 의견의 분류, 수치는 바꾸지 마.”	인용 교체, 불만의 재해석 (M07)
“교육 필요성이 잘 드러나게 해줘.”	“요구가 큰 항목부터 배치해줘. 표의 항목 수와 '-' 표시는 유지하고, 원자료에 없는 원인·빈도는 추가하지 마.”	표 행 소실, 근거 없는 원인 (M09)
“시간이 부족해. 조정해줘.”	“전체를 360분에 맞춰줘. 학습목표, 평가 계획, 핵심 실습은 유지하고, 뺀 활동과 이유를 목록으로 알려줘.”	조정 후 중간본의 목표 축소·평가 기준 누락 (M01)

수정 요청 기본 틀

[바꿀 것]을 [이렇게] 바꿔줘. 단, 다음은 그대로 유지해: [학습목표 / 평가 계획 / 인용문 / 표의 항목 수 …] 수정 후, 이번에 삭제하거나 바꾼 항목을 목록으로 알려줘.

최종본 요청

지금까지 조정한 내용으로 최종본을 정리해줘. 반드시 포함: [학습목표 / 목표–평가 대응표 / 분 단위 시간표와 합계 / 조 편성 / 평가 기준] 이전 버전에 있었는데 최종본에서 빠진 항목이 있으면 알려줘.

가이드의 한계: 이 문장들은 정렬, 척도, 교육 외 원인을 이미 아는 사람만 쓸 수 있다. 이에 따라 검수 기준을 먼저 익히고 프롬프트로 넘어가는 순서를 제안했다.